ଫାଇନ୍-ଟ୍ୟୁନିଂ ହାଇପରପାରାମିଟର

ତୁଳନାତ୍ମକ ଅଧ୍ୟୟନ

Fine-Tuning Hyperparameter Comparison

10 ବର୍ଷ ପିଲାଙ୍କ ପାଇଁ ସହଜ ଓଡ଼ିଆ ରେ ବ୍ୟାଖ୍ୟା

(Explained in Simple Odia for Kids)

Complete Hyperparameter Comparison

Setting	Bad Config	Good Config
Base LR	5e-5	2e-5
LR Scaling	sqrt(2.83x)	None
Backbone LR	1.41e-4	2e-5
Head Multiplier	10x	5x
Head LR	1.41e-3	1e-4
Class Weights	Raw Inverse	Sqrt Damped
Label Smooth	0.0	0.05
Batch Size	256	128
Steps/Epoch	~55	~110
Epochs	10	10
FP16	Yes	Yes
Freeze Phase	Ep 1-2	Ep 1-2
Optimizer Reset	Yes	Yes
LR Warmup	Yes	Yes
LR Schedule	Cosine	Cosine

ବିଷୟସୂଚୀ (Table of Contents)

1. ବେସ୍ ଲର୍ନିଂ ରେଟ୍ (Base Learning Rate)
2. LR ସ୍କେଲିଂ ନିୟମ (LR Scaling Rule)
3. ଇଫେକ୍ଟିଭ୍ ବ୍ୟାକବୋନ୍ LR (Effective Backbone LR)
4. ହେଡ୍ LR ମଲ୍ଟିପ୍ଲାୟର (Head LR Multiplier)
5. ଇଫେକ୍ଟିଭ୍ ହେଡ୍ LR (Effective Head LR)
6. କ୍ଲାସ୍ ୱେଟ୍ ଷ୍ଟ୍ରାଟେଜି (Class Weight Strategy)
7. ଲେବଲ୍ ସ୍ମୁଦିଂ (Label Smoothing)
8. ବ୍ୟାଚ୍ ସାଇଜ୍ (Batch Size)
9. ଷ୍ଟେପ୍ସ ପର୍ ଇପକ୍ (Steps Per Epoch)
10. ଇପକ୍ସ (Epochs)
11. ମିକ୍ସଡ୍ ପ୍ରିସିଜନ୍ FP16 (Mixed Precision)
12. ବ୍ୟାକବୋନ୍ ଫ୍ରିଜ୍ ଫେଜ୍ (Backbone Freeze Phase)
13. ଅପ୍ଟିମାଇଜର ରିସେଟ୍ (Optimizer Reset)
14. LR ୱାର୍ମଅପ୍ (LR Warmup After Unfreeze)
15. LR ସିଡ୍ୟୁଲ୍ - Cosine Decay (LR Schedule)

1. ବେସ୍ ଲର୍ନିଂ ରେଟ୍

(Base Learning Rate)

>> ଏହା କ'ଣ? (What is it?)

ଲର୍ନିଂ ରେଟ୍ ହେଉଛି AI ମଡେଲ ଶିଖିବାର ବେଗ। ଏହା ନିର୍ଦ୍ଧାରଣ କରେ ଯେ ମଡେଲ ପ୍ରତ୍ୟେକ ଥର ଭୁଲରୁ କେତେ ବଡ଼ ପଦକ୍ଷେପ ନେଇ ସଂଶୋଧନ କରିବ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ଏକ ପାହାଡ଼ ଉପରେ ଛ ଏବଂ ତଳକୁ ସବୁଠାରୁ ନିମ୍ନ ସ୍ଥାନ (valley) ଖୋଜୁଛ।

- ବଡ଼ ପାଦ (5e-5): ତୁମେ ବଡ଼ ବଡ଼ ଲମ୍ଫ ଦେଇ ଛୁଟୁଛ। ତୁମେ valley ଟିକୁ ଡେଇଁ ପାର ହୋଇ ଯାଉଛ! ଆଉଥରେ ଆସିଲେ ଅନ୍ୟ ପଟକୁ ଡେଇଁ ଯାଉଛ। କେବେ ବି ଭଲ ଜାଗାରେ ରହି ପାରୁ ନାହଁ।

- ଛୋଟ ପାଦ (2e-5): ତୁମେ ଧୀରେ ଧୀରେ ଚାଲୁଛ। ପ୍ରତ୍ୟେକ ପଦକ୍ଷେପ ଛୋଟ। ତୁମେ ସଠିକ୍ ଭାବରେ valley ର ସବୁଠାରୁ ନିମ୍ନ ସ୍ଥାନରେ ପହଞ୍ଚୁଛ!

ଗୋଟେ ବାସ୍ତବ ଉଦାହରଣ: ଧରା ତୁମ ମା ତୁମକୁ କହିଲେ ଅନ୍ଧାରରେ ବାଥରୁମ ଯିବାକୁ। ବଡ଼ ପାଦରେ ଗଲେ ଦୟାଲରେ ଧକ୍କା ଲାଗିବ! ଛୋଟ ପାଦରେ ଗଲେ ସୁରକ୍ଷିତ ଭାବରେ ପହଞ୍ଚିବ।

>> ତୁଳନା:

Aggressive: 5e-5
ବହୁତ ବଡ଼ ପାଦ = Valley ମିସ୍!

Corrected: 2e-5
ଛୋଟ ପାଦ = Valley ପହଞ୍ଚିବ!

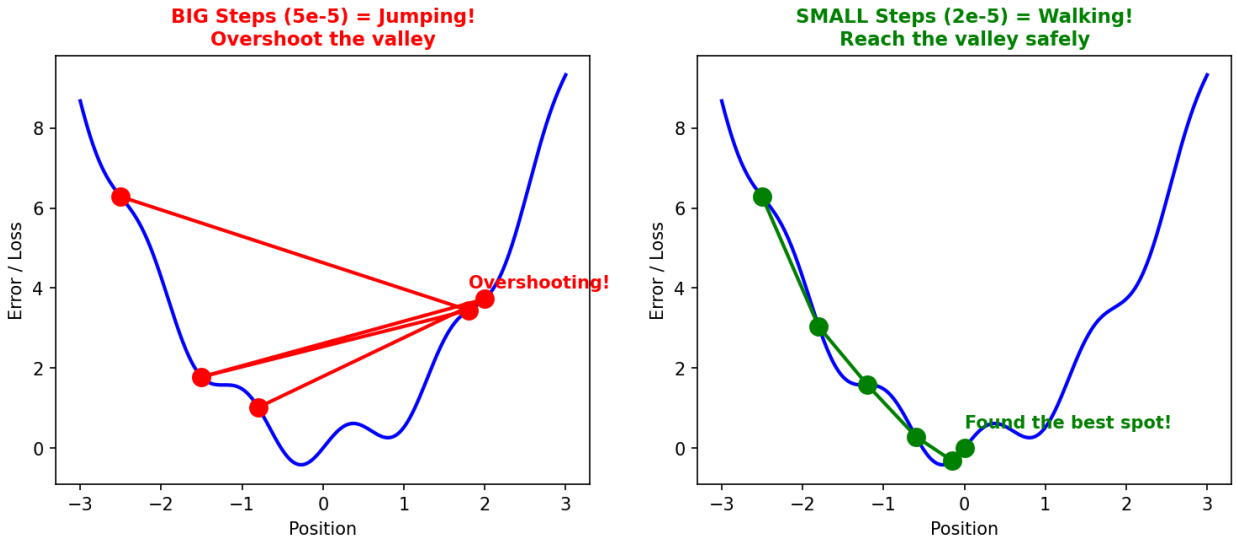

କାହିଁକି ଏହା ଗୁରୁତ୍ୱପୂର୍ଣ୍ଣ: ନିମ୍ନ ବେସ୍ ଲର୍ନିଂ ରେଟ୍ ମଡେଲକୁ ଭଲ ସ୍ଥାନ (good minima) ଡେଇଁ ନ ଯିବାରୁ ରକ୍ଷା କରେ। ଏହା ଯେପରି ଧୀରେ ଧୀରେ ଚାଲି ସଠିକ୍ ରାସ୍ତା ଖୋଜିବା।

2. LR ସ୍କଲିଂ ନିୟମ

(LR Scaling Rule)

>> ଏହା କ'ଣ? (What is it?)

LR Scaling ହେଉଛି ବ୍ୟାଚ୍ ସାଇଜ୍ ଅନୁସାରେ ଲର୍ନିଂ ରେଟ୍ କୁ ବଢ଼ାଇବା । sqrt(batch/32) ସୂତ୍ର ଅନୁସାରେ ବ୍ୟାଚ୍ ସାଇଜ୍ 256 ରେ LR ଟି 2.83 ଗୁଣ ବଢ଼ିଯାଏ!

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ସାଇକଲେ ଚଳାଉଛ ଏକ ରାସ୍ତାରେ ।

- Scaling ସହ (2.83x): ଏହା ଯପେରି ସାଇକଲେରେ ରକେଟ ଲଗାଇ ଦଲେେ! ବହୁତ ତଜେ ହେ ।ଇଗଲା । ତୁମେ ରାସ୍ତାରୁ ବାହାରି ଯାଉଛ, ବଙ୍କା ରାସ୍ତାରେ ଧକ୍କା ଲାଗୁଛି!

- Scaling ବିନା: ଏହା ଯପେରି ସାମାନ୍ୟ ବଗେରେ ସାଇକଲେ ଚଳାଉଛ । ରାସ୍ତାରେ ସୁରକ୍ଷିତ ଭାବେ ଯାଉଛ, ବଙ୍କା ରାସ୍ତାରେ ମଧ୍ୟ ସଠିକ ଭାବେ ବଙ୍କୁଛ ।

ବାସ୍ତବ ଉଦାହରଣ: ସ୍କୁଲ ବସ ଗାଁ ରାସ୍ତାରେ ଧୀରେ ଯାଏ (scaling ନାହିଁ) । ଯଦି ବସ ହାଇୱେ ବଗେରେ ଗାଁ ରାସ୍ତାରେ ଯାଏ (scaling ଅଛି), ତବେ ଦୁର୍ଘଟଣା ହବେ!

Aggressive: sqrt scaling = 2.83x
ବହୁତ ଅଧିକ ବଗେ = ଅସ୍ଥିର!

Corrected: No scaling
ସାମାନ୍ୟ ବଗେ = ସ୍ଥିର!

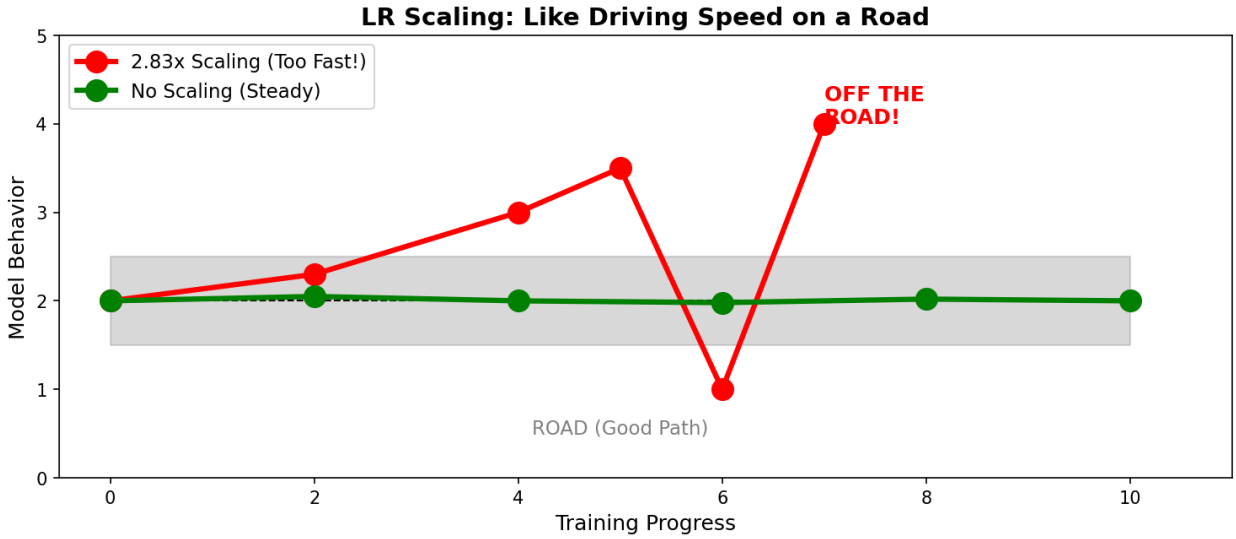

3. ଇଫେକ୍ଟିଭ୍ ବ୍ୟାକବୋନ୍ LR

(Effective Backbone LR)

>> ଏହା କ'ଣ?

Backbone ହେଉଛି AI ମଡେଲର ମୂଳ ମସ୍ତିଷ୍କ । ଏହା ପୂର୍ବରୁ ଲକ୍ଷ ଲକ୍ଷ ଛବି ଦେଖି ଶିଖିସାରିଛି (pre-trained) । ଏହାର LR ବହୁତ ଛୋଟ ହେବା ଦରକାର, କାରଣ ଏହା ପୂର୍ବରୁ ଜ୍ଞାନୀ ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମ ବାପା ଜଣେ ଅଭିଜ୍ଞ ରୋଷୟା (experienced cook) । ସେ 20 ବର୍ଷ ଧରି ରାନ୍ଧୁଛନ୍ତି ।

- Aggressive (1.41e-4): ଏହା ଯେପରି ତୁମ ବାପାଙ୍କୁ କହିବା "ସବୁ ଭୁଲି ଯାଅ, ନୂଆ ଭାବେ ଶିଖ!" ଏହା ବୁଦ୍ଧିମାନ ନୁହଁ! ସେ ତାଙ୍କ 20 ବର୍ଷର ଅଭିଜ୍ଞତା ହରାଇବେ!

- Corrected (2e-5): ଏହା ଯେପରି ତୁମ ବାପାଙ୍କୁ କହିବା "ଆପଣ ଭଲ ଜାଣନ୍ତି, ବସ୍ ଟିକିଏ ନୂଆ ମସଲା ବ୍ୟବହାର କରନ୍ତୁ ।" ସେ ପୁରୁଣା ଜ୍ଞାନ ରଖି ନୂଆ ଜିନିଷ ଶିଖିବେ!

Aggressive config ରେ backbone LR 7 ଗୁଣ ବେଶୀ ଥିଲା । ଏହା ପୂର୍ବ ଜ୍ଞାନ ନଷ୍ଟ କରିଦିଏ!

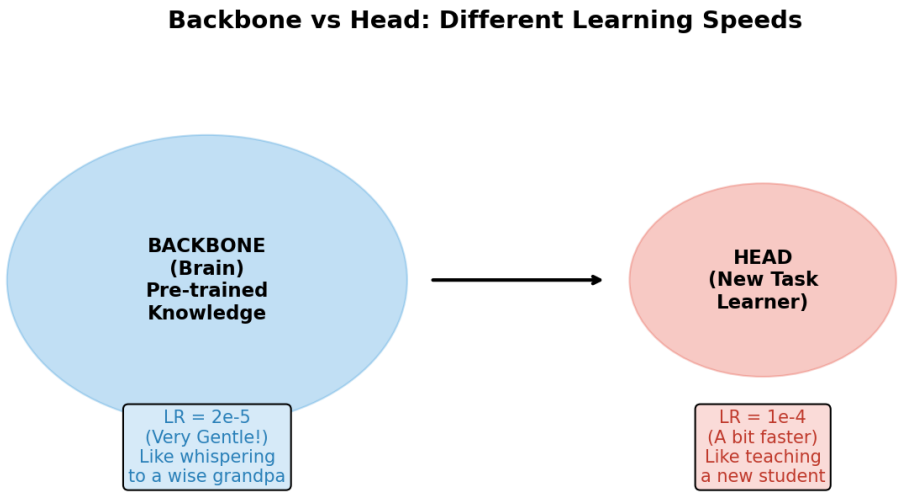

4. ହେଡ୍ LR ମଲ୍ଟିପ୍ଲାୟର

(Head LR Multiplier)

>> ଏହା କ'ଣ?

Head (ହେଡ୍) ହେଉଛି ମଡେଲର ଶେଷ ଭାଗ ଯାହା ସିଦ୍ଧାନ୍ତ ନିଏ - "ଏହା ବିଲେଇ ନା କୁକୁର?" Head Multiplier ହେଡ୍ ର ଶିଖିବା ବେଗକୁ backbone ଠାରୁ ଅଧିକ କରେ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମ କ୍ଲାସରେ ଗେ ାଟେ ନୂଆ ପିଲା ଆସିଛି। ସେ ବହୁତ ଜଲ୍ଦି ଶିଖିବାକୁ ଚାହୁଁଛି।

- 10x Multiplier: ଏହା ଯେପରି ନୂଆ ପିଲାଟି ଏକା ଦିନରେ ସବୁ ବିଷୟ ଶିଖିବାକୁ ଚେଷ୍ଟା କରୁଛି! ଫଳ? ସବୁ ଗେ ାଳମାଳ ହେ ାଇଯାଏ, କିଛି ମଧ୍ୟ ଠିକ ସେ ଶିଖେ ନାହିଁ।

- 5x Multiplier: ଏହା ଯେପରି ନୂଆ ପିଲାଟି ପ୍ରତିଦିନ ଟିକେ ଟିକେ ଶିଖୁଛି। ଆଜି ଗଣିତ, କାଲି ବିଜ୍ଞାନ। ସେ ସଠିକ ଭାବେ ସବୁ ଶିଖିବ!

ଯେପରି ଟିଭି ର volume: 10x = volume ବହୁତ ଜେ ାରରେ = କାନ ଦରଜ!
5x = volume ଠିକ ଅଛି = ସୁନ୍ଦର ଭାବେ ଶୁଣାଯାଉଛି!

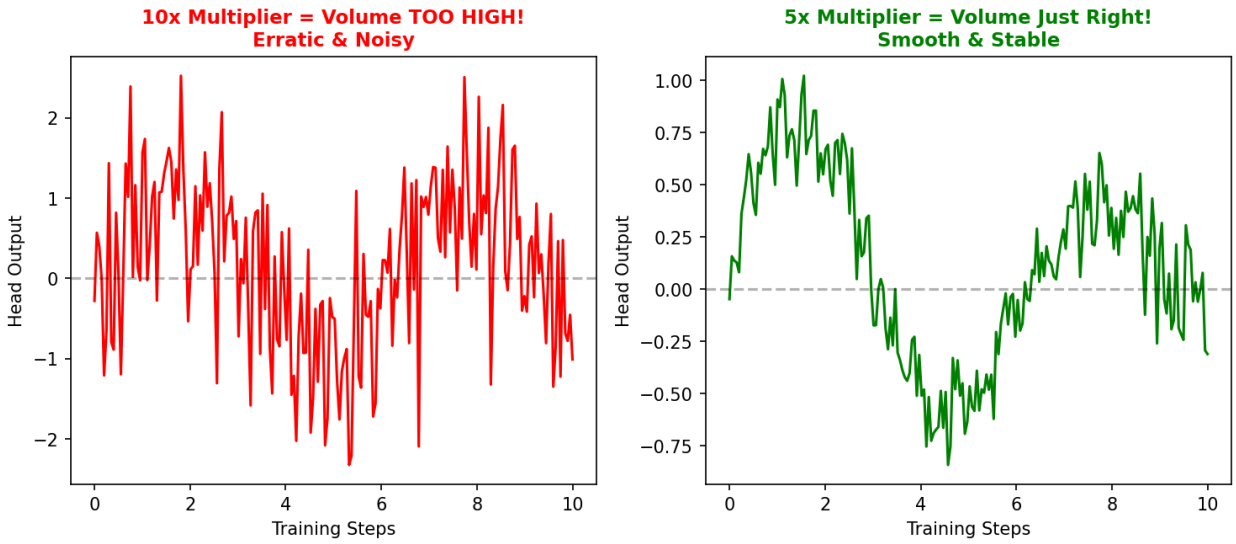

5. ଇଫେକ୍ଟିଭ୍ ହେଡ୍ LR

(Effective Head LR)

>> ଏହା କ'ଣ?

ଏହା ହେଉଛି ହେଡ୍ ପ୍ରକୃତରେ କେତେ ବେଗରେ ଶିଖୁଛି ତାହାର ଫଳ । Base LR x Scaling x Multiplier = Effective Head LR । Aggressive ରେ ଏହା 1.41e-3 ଥିଲା, Corrected ରେ 1e-4 (14 ଗୁଣ କମ!) ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ଏକ ପରୀକ୍ଷା ପାଇଁ ପଢୁଛ ।

- Head LR 1.41e-3 (ବହୁତ ଅଧିକ): ଏହା ଯପେରି ତୁମେ ରାତି ସାରା ଜାଗି 5 ଟା ବିଷୟ ପଢୁଛ, କଫି ପିଇ ପିଇ! ଫଳ? ସକାଳୁ ସବୁ ଭୁଲି ଯାଉଛ, ମୁଣ୍ଡ ବିନ୍ଧୁଛି!

- Head LR 1e-4 (ଠିକ ଅଛି): ଏହା ଯପେରି ତୁମେ ପ୍ରତିଦିନ 1 ଘଣ୍ଟା ଶାନ୍ତ ମନରେ ପଢୁଛ । ସବୁ ମନେ ରହୁଛି, ପରୀକ୍ଷାରେ ଭଲ ନମ୍ବର ଆସୁଛି!

ଅତ୍ୟଧିକ Head LR classifier ତ୍ରାଣ୍ଟିକ (erratic) ଭାବେ ଟ୍ରେନ୍ ହୁଏ । ଏହା ଯପେରି ଗେ ।ଟେ ପାଗଳ ପେନ୍ସିଲ ଯାହା ସବୁ ଦିଗରେ ଲେଖୁଛି ବିନା ନିୟନ୍ତ୍ରଣ!

6. କ୍ଲାସ୍ ୱେଟ୍ ଷ୍ଟ୍ରାଟେଜି

(Class Weight Strategy)

>> ଏହା କ'ଣ?

ଯତେବେଳେ କିଛି category ରେ ବହୁତ data ଅଛି ଏବଂ କିଛି ରେ କମ ଅଛି, class weights ନିର୍ଦ୍ଧାରଣ କରେ ପ୍ରତ୍ୟେକ category କୁ କତେ ଧ୍ୟାନ ଦେବାକୁ ହେବେ ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମ ସ୍କୁଲ କ୍ଲାସରେ 3 ଟି ଗ୍ରୁପ ଅଛି:
- ଗ୍ରୁପ A: 40 ଜଣ ପିଲା (ବହୁତ ଅଧିକ)
- ଗ୍ରୁପ B: 25 ଜଣ ପିଲା (ମଧ୍ୟମ)
- ଗ୍ରୁପ C: 5 ଜଣ ପିଲା (ବହୁତ କମ)

Raw Inverse Frequency: ଶିକ୍ଷକ ଗ୍ରୁପ C କୁ 8 ଗୁଣ ଅଧିକ ସମୟ ଦିଅନ୍ତି! ଗ୍ରୁପ A ଓ B ଅବହଳେିତ ହେ ।ଇଯାନ୍ତି । ଗ୍ରୁପ C ସବୁ ନିୟନ୍ତ୍ରଣ କରେ!

Sqrt Dampened: ଶିକ୍ଷକ ଗ୍ରୁପ C କୁ ଟିକେ ଅଧିକ ସମୟ ଦିଅନ୍ତି (2.83x) କିନ୍ତୁ ସମସ୍ତଙ୍କୁ ନ୍ୟାୟ ଭାବେ ପଢ଼ାନ୍ତି । ସବୁ ଗ୍ରୁପ ଭଲ ଭାବେ ଶିଖନ୍ତି!

ବାସ୍ତବ ଉଦାହରଣ: ଯଦି ତୁମ ମା 3 ଟି ପିଲାଙ୍କ ମଧ୍ୟରୁ ସବୁଠାରୁ ଛେ ।ଟ ପିଲାଟିକୁ ବହୁତ ଅଧିକ ଧ୍ୟାନ ଦିଅନ୍ତି, ବଡ଼ ପିଲାମାନେ ଅସନ୍ତୁଷ୍ଟ ହୁଅନ୍ତି! ସମସ୍ତଙ୍କୁ ସମାନ ଭାବେ ଯତ୍ନ ନେବା ଦରକାର ।

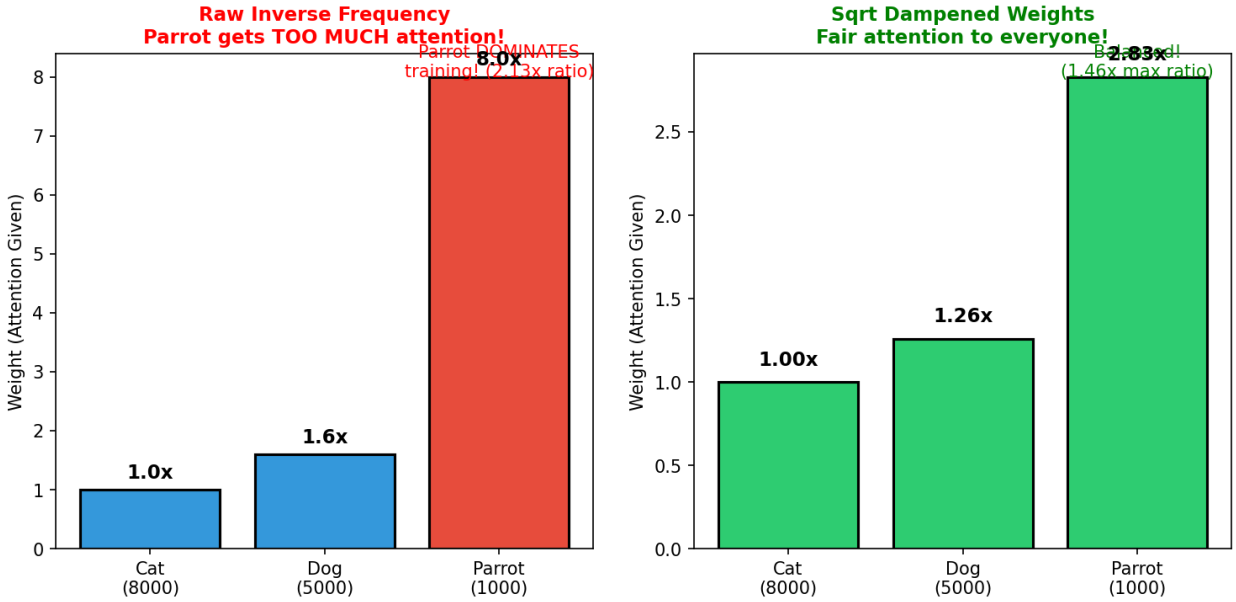

7. ଲେବେଲ୍ ସ୍ମୁଦିଂ

(Label Smoothing)

>> ଏହା କ'ଣ?

Label Smoothing ମଡେଲକୁ 100% ଆତ୍ମବିଶ୍ୱାସୀ ହେବାରୁ ରୋକେ। 0.05 label smoothing ର ଅର୍ଥ ହେଉଛି ମଡେଲ 95% ନିଶ୍ଚିତ ଓ 5% ଅନିଶ୍ଚିତ ରହିବ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମ ବନ୍ଧୁ ପଚାରୁଛି "ଆଜି ବୃଷ୍ଟି ହେବ କି?"

- Label Smoothing ବିନା (0.0): ତୁମେ କହୁଛ "100% ବୃଷ୍ଟି ହେବ! ମୁଁ ଜାଣେ!" ଯଦି ବୃଷ୍ଟି ନ ହୁଏ, ତୁମ ଉପରେ କେହି ବିଶ୍ୱାସ କରିବ ନାହିଁ!

- Label Smoothing ସହ (0.05): ତୁମେ କହୁଛ "95% ବୃଷ୍ଟି ହେବ, ତେବେ ଛାତି ନେଇ ଯାଅ, କିନ୍ତୁ ହେଇନପାରେ ମଧ୍ୟ।" ଏହା ବୁଦ୍ଧିମାନ ଉତ୍ତର!

ବାସ୍ତବ ଉଦାହରଣ: ଗେଟେ ଡାକ୍ତର "100% ଠିକ ହେଇଯିବ" କହିଲେ ସେଟା ଅତ୍ୟଧିକ ଆତ୍ମବିଶ୍ୱାସ। "95% ସମ୍ଭାବନା ଅଛି ଠିକ ହେବାର" କହିଲେ ସେଟା ବିଶ୍ୱାସଯୋଗ୍ୟ ଓ ସଠିକ।

Label Smoothing overconfidence (ଅତ୍ୟଧିକ ଆତ୍ମବିଶ୍ୱାସ) କୁ ରୋକେ ଏବଂ ମଡେଲ ନୂଆ data ଉପରେ ମଧ୍ୟ ଭଲ କାମ କରେ (generalization)!

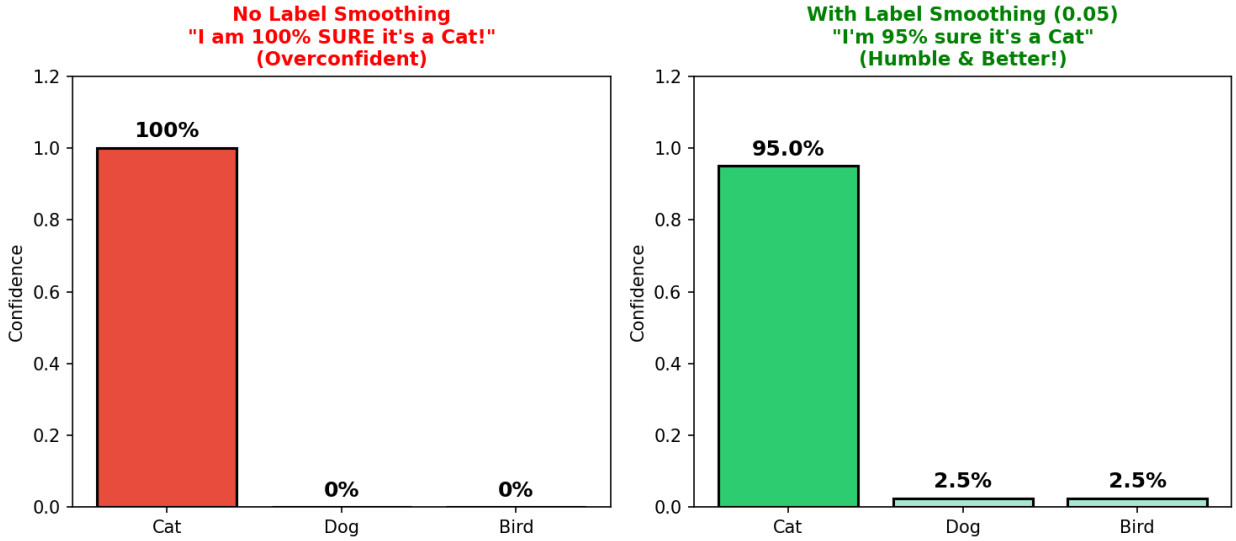

୪. ବ୍ୟାଚ୍ ସାଇଜ୍

(Batch Size)

>> ଏହା କ'ଣ?

Batch Size ହେଉଛି ମଡେଲ ଏକ ସମୟରେ କେତେ ଗେ ାଟି data sample ଦେଖି ଶିଖିବ ତାହା। ବଡ଼ batch = ଅଧିକ data ଏକାସାଙ୍ଗେ, ଛେ ାଟ batch = କମ data ଗେ ାଟିଏ ଥରରେ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ଜଣେ ଶିକ୍ଷକ ଏବଂ 14,000 ଖାତା ଯାଞ୍ଚ (check) କରିବାକୁ ଅଛି।

- Batch 256: ତୁମେ ଏକା ଥରରେ 256 ଟି ଖାତା ଉଠାଇ ଯାଞ୍ଚ କରୁଛ। ବହୁତ ଅଧିକ ଖାତା ଥିବାରୁ ସୂକ୍ଷ୍ମ ଭୁଲ ଦେଖି ପାରୁ ନାହଁ। ମାତ୍ର 55 ଥର ଯାଞ୍ଚ ସେସନ ହୁଏ।

- Batch 128: ତୁମେ 128 ଟି ଖାତା ଉଠାଇ ଯାଞ୍ଚ କରୁଛ। ଅଧିକ ଧ୍ୟାନ ଦେଇ ପାରୁଛ। 110 ଥର ଯାଞ୍ଚ ସେସନ ହୁଏ = ଅଧିକ ସୂକ୍ଷ୍ମ ଯାଞ୍ଚ!

ବାସ୍ତବ ଉଦାହରଣ: ଗେ ାଟେ ଡାକ୍ତର ଦିନକୁ 50 ରେ ାଗୀ ଦେଖିଲେ ସମସ୍ତଙ୍କୁ ଭଲ ଭାବେ ଦେଖି ପାରିବେ। 200 ରେ ାଗୀ ଦେଖିଲେ ସମୟ କମ ପଡ଼ିବ!

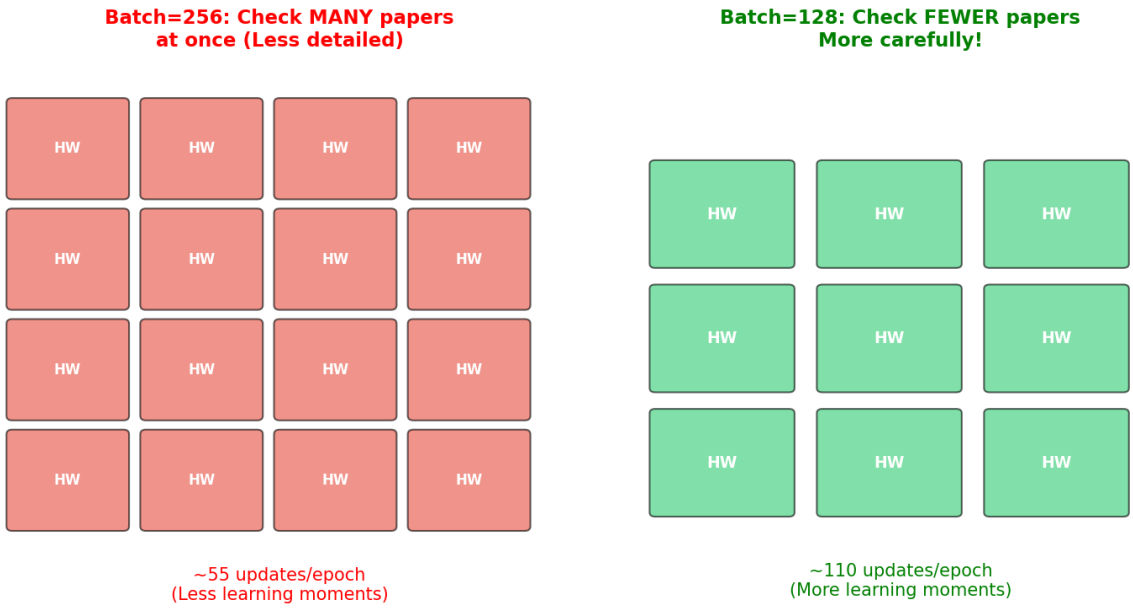

9. ଷ୍ଟେପ୍ସ ପର୍ ଇପକ୍

(Steps Per Epoch)

>> ଏହା କ'ଣ?

Steps Per Epoch = ଗଣ ।ଟିଏ epoch ରେ ମଡେଲ କେତେ ଥର update ହୁଏ । ଅଧିକ steps = ଅଧିକ ଅଭ୍ୟାସ ସୁଯୋଗ ।ଗ । 14k samples ସହ batch 128 ରେ ~110 steps ହୁଏ ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ କ୍ରିକେଟ୍ ଖେଳିବା ଶିଖୁଛ ।

- 55 ଷ୍ଟେପ୍ (batch 256): ତୁମେ ଦିନକୁ ମାତ୍ର 55 ଟି ବଲ ଖେଳୁଛ । ଅଭ୍ୟାସ କମ, ଶିଖିବା ଧୀର!

- 110 ଷ୍ଟେପ୍ (batch 128): ତୁମେ ଦିନକୁ 110 ଟି ବଲ ଖେଳୁଛ! ଦୁଇ ଗୁଣ ଅଭ୍ୟାସ = ଦୁଇ ଗୁଣ ଭଲ ଶିଖିବ!

ବାସ୍ତବ ଉଦାହରଣ: ଯଉଁ ପିଲା ଦିନକୁ 2 ଘଣ୍ଟା ଅଭ୍ୟାସ କରେ, ସେ 1 ଘଣ୍ଟା ଅଭ୍ୟାସ କରୁଥିବା ପିଲାଠାରୁ ନିଶ୍ଚୟ ଭଲ ଖେଳିବ!

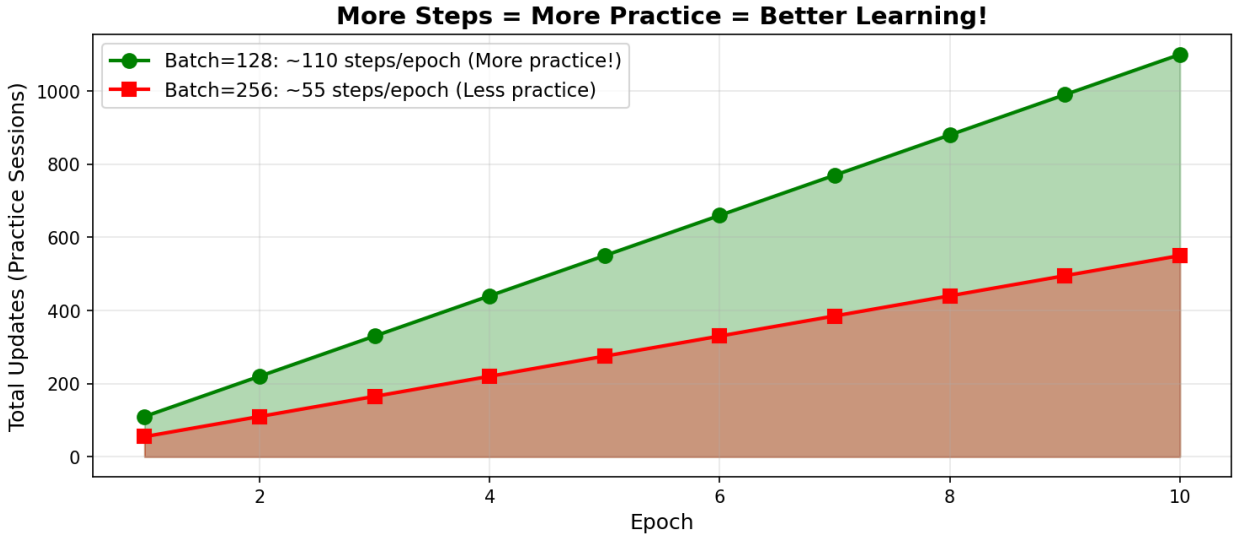

10. ଇପକ୍ସ

(Epochs)

>> ଏହା କ'ଣ?

Epoch ହେଉଛି ସମ୍ପୂର୍ଣ୍ଣ dataset ଉପରେ ଗୋଟିଏ ଥର ଶିକ୍ଷା । 10 epochs = ସମ୍ପୂର୍ଣ୍ଣ dataset 10 ଥର ଦେଖିବା । ଦୁଇ config ରେ ସମାନ 10 epochs ଅଛି ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମ ପାଖରେ ଗୋଟେ ଗଣିତ ବହି ଅଛି ।

- 1 Epoch = ବହିଟି 1 ଥର ପଢ଼ିବା । ଟିକେ ଶିଖିଲ ନା, କିନ୍ତୁ ଅନେକ ଜିନିଷ ଭୁଲିଯିବ ।
- 5 Epochs = ବହିଟି 5 ଥର ପଢ଼ିବା । ଅଧିକାଂଶ ଜିନିଷ ମନେ ରହିଲା!
- 10 Epochs = ବହିଟି 10 ଥର ପଢ଼ିବା । ସବୁ ଜିନିଷ ଭଲ ଭାବେ ମନେ ଅଛି!

କିନ୍ତୁ ସାବଧାନ! 100 ଥର ପଢ଼ିଲେ? ତୁମେ ମାତ୍ର ବହିଟି ମୁଖସ୍ଥ କରିବ, ନୂଆ ପ୍ରଶ୍ନ ପଚାରିଲେ ଉତ୍ତର ଦେଇ ପାରିବ ନାହିଁ! ଏହାକୁ overfitting କୁହାଯାଏ ।

10 epochs ହେଉଛି ଠିକ ସନ୍ତୁଳନ - ଯଥେଷ୍ଟ ଶିକ୍ଷା, ଅତ୍ୟଧିକ ମୁଖସ୍ଥ ନୁହଁ!

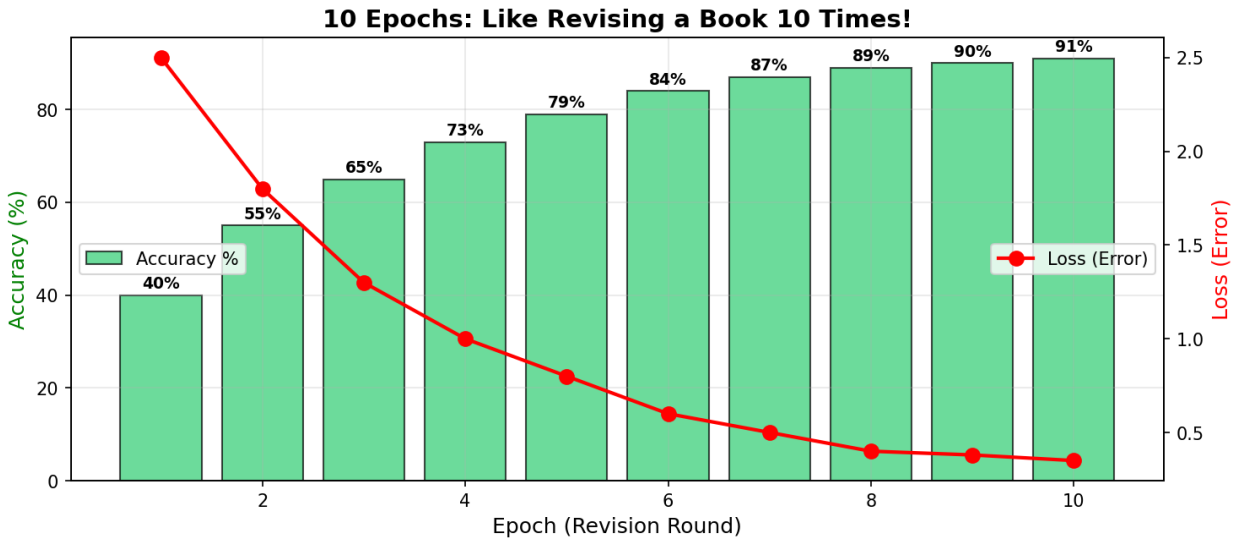

11. ମିକ୍ସଡ୍ ପ୍ରିସିଜନ୍ (FP16)

(Mixed Precision)

>> ଏହା କ'ଣ?

FP16 (Half Precision) ହେଉଛି ସଂଖ୍ୟାଗୁଡ଼ିକୁ 32 bit ବଦଳରେ 16 bit ରେ store କରିବା। ଏହା GPU memory ଅଧା ବ୍ୟବହାର କରେ ଏବଂ training ତେଜେ ହୁଏ!

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମ ସ୍କୁଲ ବ୍ୟାଗ ରେ ବହି ରଖୁଛ।

- FP32 (Full Precision): ତୁମେ ସବୁ ବହି ବଡ଼ ସାଇଜ ରେ ନେଉଛ। ବ୍ୟାଗ ବହୁତ ଭାରି! ପିଠି ଦରଜ ହୁଏ!

- FP16 (Half Precision): ତୁମେ ସବୁ ବହି ଛୋଟ (pocket) ସାଇଜ ରେ ନେଉଛ। ବ୍ୟାଗ ଅଧା ଭାରି! ଆରାମରେ ସ୍କୁଲ ଯାଉଛ! ଏବଂ ବହିରେ ସବୁ ସମାନ ଲେଖା ଅଛି!

ବାସ୍ତବ ଉଦାହରଣ: ଗୋଟେ ଫୋଟୋ । JPEG (ଛୋଟ) ବା PNG (ବଡ଼) ରେ save କରିପାରିବ। JPEG ଛୋଟ ହେଲେ ମଧ୍ୟ ଫୋଟୋ । ଲଗଭଗ ସମାନ ଦେଖାଯାଏ!

ଦୁଇ config ରେ FP16 ବ୍ୟବହାର ହୋଇଛି - ଏହା ସର୍ବଦା ଭଲ!

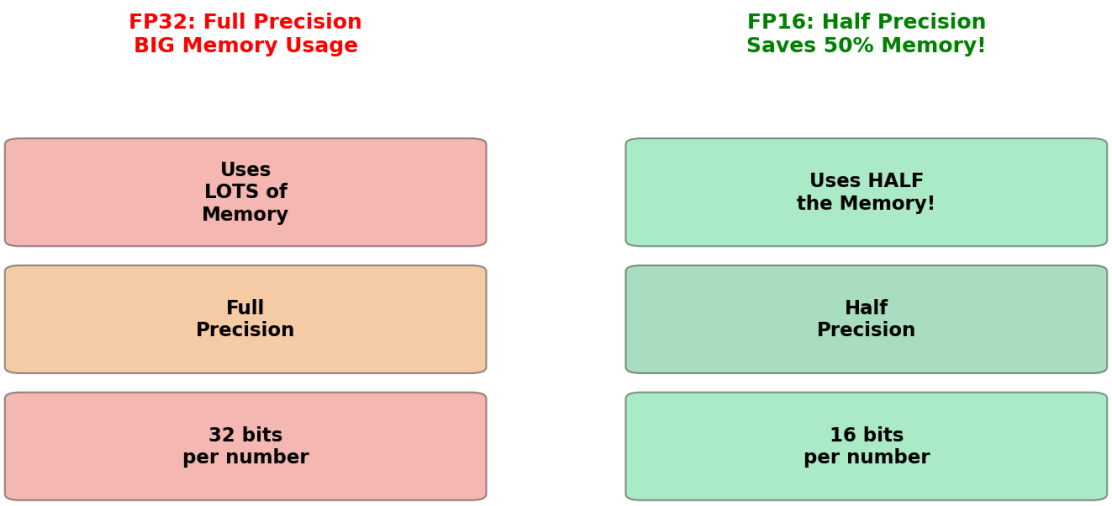

12. ବ୍ୟାକବୋନ୍ ଫ୍ରିଜ୍ ଫେଜ୍

(Backbone Freeze Phase)

>> ଏହା କ'ଣ?

ପ୍ରଥମ 1-2 epochs ରେ backbone (ମୂଳ ମସ୍ତିଷ୍କ) freeze ରଖାଯାଏ - ଅର୍ଥାତ୍ backbone ଶିଖେ ନାହିଁ, କେବଳ head (ସିଦ୍ଧାନ୍ତ ନେଉଥିବା ଅଂଶ) ଶିଖେ। ଏହା head କୁ ପ୍ରଥମେ ସ୍ଥିର ହେବାକୁ ସୁଯୋଗ ଦିଏ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ସାଇକଲେ ଶିଖୁଛ।

- Freeze Phase (Epoch 1-2): ପ୍ରଥମେ training wheels (ସହାୟକ ଚକ) ଲଗାଇ ଶିଖୁଛ। ତୁମେ balance ଧରିବା ଶିଖୁଛ ସୁରକ୍ଷିତ ଭାବେ। ଏଠି backbone (ସାଇକଲେ) ସ୍ଥିର ଅଛି, ତୁମେ (head) ଶିଖୁଛ।

- Unfreeze (Epoch 3+): Training wheels ଖୋଲିଦିଆଗଲା! ଏବେ ତୁମେ ପ୍ରକୃତ ସାଇକଲେ ଚଳାଉଛ। ଦୁଇଟି ଅଂଶ (backbone + head) ଏକାସାଙ୍ଗେ ଶିଖୁଛନ୍ତି!

ବାସ୍ତବ ଉଦାହରଣ: ସ୍କୁଲରେ ନୂଆ ପିଲା ପ୍ରଥମେ ନିୟମ ଶିଖେ (freeze phase), ତାପରେ ଖେଳେ, ପଢ଼ା ସବୁ ଆରମ୍ଭ କରେ (unfreeze phase)!

Backbone Freeze: Like Training Wheels on a Bicycle!

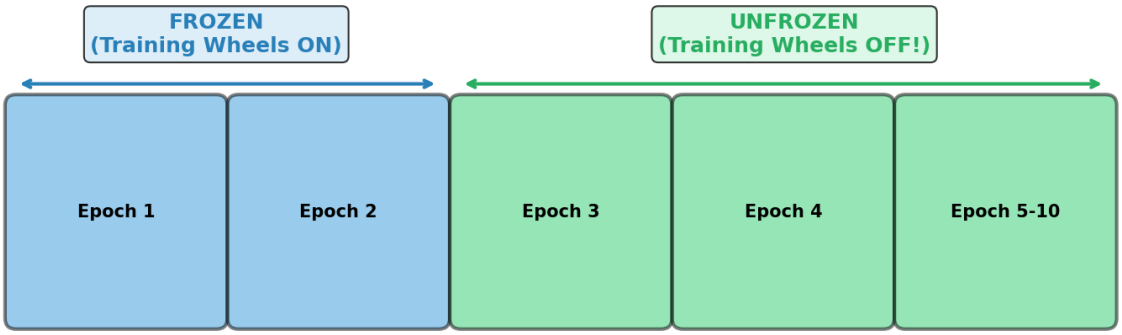

Head learns first (baby steps), then backbone joins (full learning)!

13. ଅପ୍‌ଟିମାଇଜର ରିସେଟ୍

(Optimizer Reset at Unfreeze)

>> ଏହା କ'ଣ?

Backbone unfreeze ହଲେ। ପରେ optimizer (ଶିକ୍ଷା ନିୟନ୍ତ୍ରକ) କୁ ନୂଆ ଭାବେ ଆରମ୍ଭ କରାଯାଏ। ପୁରୁଣା momentum (ଗତି) ବ୍ୟବହାର ନ କରି fresh start ଦିଆଯାଏ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ଏକ ଖେଳେ ଖେଳୁଛ। ପ୍ରଥମ ରାଉଣ୍ଡ ସରିଗଲା।

- Reset ବିନା: ତୁମେ ପ୍ରଥମ ରାଉଣ୍ଡର ନିୟମ ମନେ ରଖି ଦ୍ୱିତୀୟ ରାଉଣ୍ଡ ଖେଳୁଛ। କିନ୍ତୁ ଦ୍ୱିତୀୟ ରାଉଣ୍ଡର ନିୟମ ଅଲଗା! ତୁମେ ଭୁଲ ନିୟମରେ ଖେଳୁଛ!

- Reset ସହ: ତୁମେ ପ୍ରଥମ ରାଉଣ୍ଡ ସରିଲା ପରେ ମନ ସଫା କରି ନୂଆ ରାଉଣ୍ଡ ଆରମ୍ଭ କରୁଛ। ନୂଆ ନିୟମ ସଠିକ ଭାବେ ଶିଖୁଛ!

ବାସ୍ତବ ଉଦାହରଣ: ଯପେରି ନୂଆ ସମେଷ୍ଟର ଆରମ୍ଭ ହଲେ ନୂଆ ଖାତା ବ୍ୟବହାର କରିବା। ପୁରୁଣା ଖାତାରେ ନୂଆ ବିଷୟ ଲଖେଲେ ଗେ ।ଳମାଳ ହୁଏ!

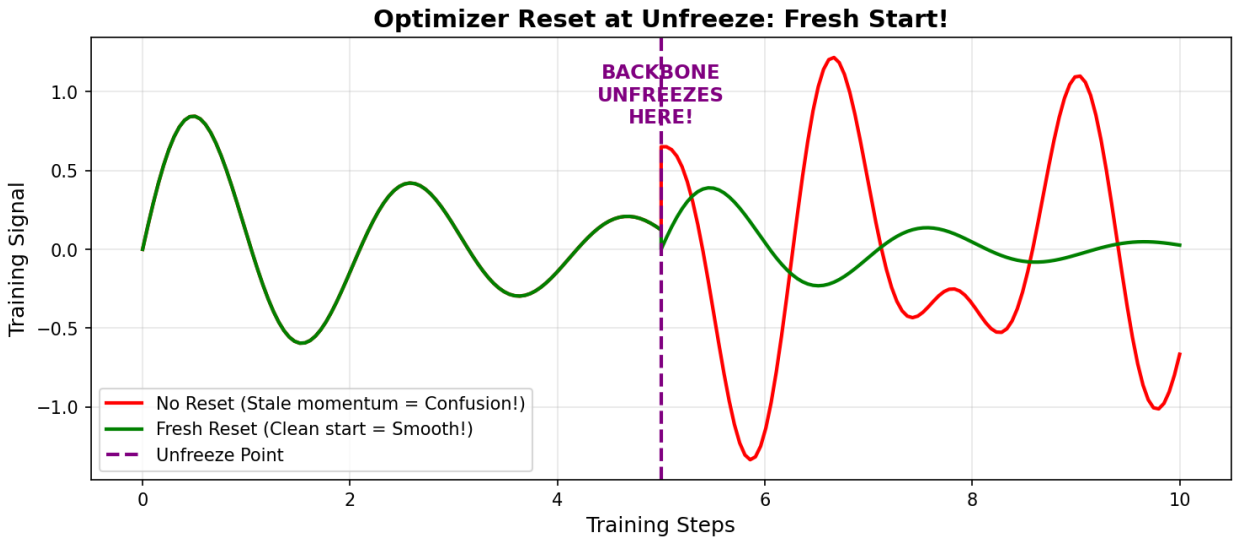

14. LR ୱାର୍ମଅପ୍

(LR Warmup After Unfreeze)

>> ଏହା କ'ଣ?

Backbone unfreeze ହେଲା ପରେ learning rate ସଙ୍ଗେ ସଙ୍ଗେ ପୂରା ମାତ୍ରାରେ ନ ଦେଇ ଧୀରେ ଧୀରେ ବଢ଼ାଇବା । ଏହା initial instability (ଆରମ୍ଭିକ ଅସ୍ଥିରତା) ରୁ ରକ୍ଷା କରେ ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ସକାଳୁ ଉଠି ଦୌଡ଼ିବାକୁ ଯାଉଛ ।

- Warmup ବିନା: ତୁମେ ଶୋଇଥିବା ଅବସ୍ଥାରୁ ଉଠି ସିଧା ପୂରା ବେଗରେ ଦୌଡ଼ିବା ଆରମ୍ଭ କଲ! ମାଂସପେଶୀ ଟାଣି ହୋଇଯିବ! ଆଘାତ ଲାଗିବ!

- Warmup ସହ: ତୁମେ ପ୍ରଥମେ ଧୀରେ ଚାଲିଲ, ତାପରେ ଜୋଗିଂ କଲ, ତାପରେ ଦୌଡ଼ିଲ । ଶରୀର ଗରମ ହୋଇସାରିଛି, କୌଣସି ଆଘାତ ନାହିଁ!

ବାସ୍ତବ ଉଦାହରଣ: ଗାଡ଼ି ଚଳାଇବା ସମୟରେ engine କୁ ପ୍ରଥମେ ଗରମ ହେବାକୁ ଦେବା ଦରକାର । ଠଣ୍ଡା engine ରେ ସିଧା ତେଜେ ଗଲେ engine ଖରାପ ହୋଇଯିବ!

ଦୁଇ config ରେ warmup ବ୍ୟବହାର ହୋଇଛି - ଏହା ସର୍ବଦା ଜରୁରୀ!

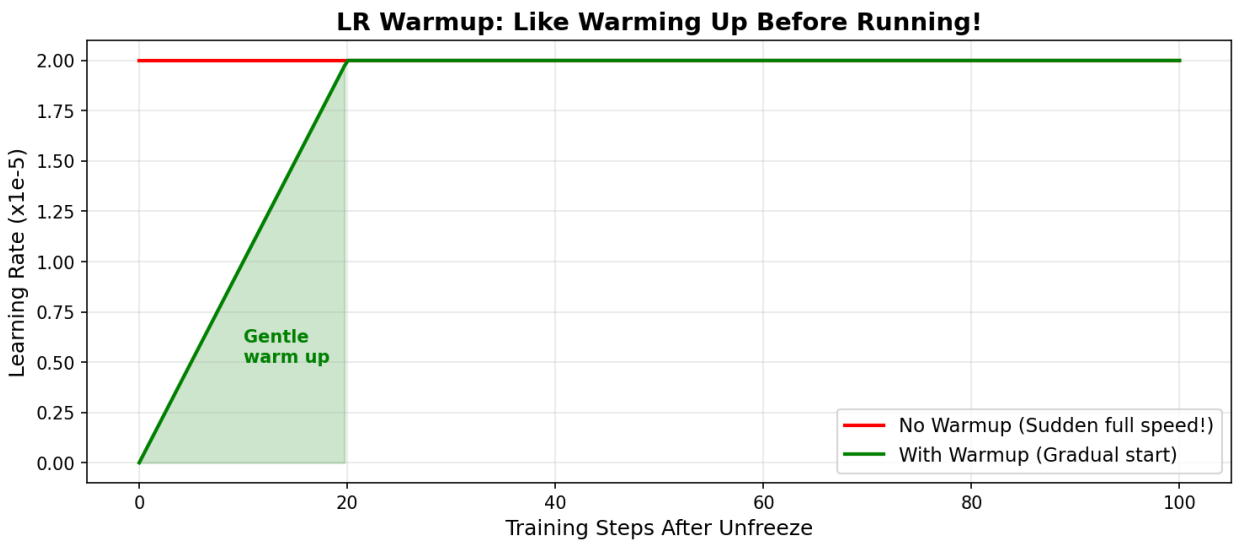

15. LR ସିଡ୍ୟୁଲ୍ - Cosine Decay

(LR Schedule - Cosine Decay)

>> ଏହା କ'ଣ?

Cosine Decay ହେଉଛି ଏକ ସୁନ୍ଦର ଏବଂ ସ୍ମୁଦ୍ (smooth) ଉପାୟରେ learning rate କୁ training ସମୟରେ ଧୀରେ ଧୀରେ କମାଇବା । ଆରମ୍ଭରେ ଅଧିକ, ଶେଷରେ ବହୁତ କମ ।

>> 10 ବର୍ଷ ପିଲା ପାଇଁ ଉଦାହରଣ:

ଧରା ତୁମେ ବଜାରରୁ ଘରକୁ ସାଇକଲେ ଚଳାଇ ଆସୁଛ ।

- Cosine Decay: ଆରମ୍ଭରେ ତୁମେ ତେଜ ଭାବେ ପେଡାଲ ମାରୁଛ (high LR) । ଘର ପାଖେ ଆସିଲା ପରେ ଧୀରେ ଧୀରେ ବେଗ କମାଉଛ । ଘର ଆଗରେ ସ୍ମୁଦ ଭାବେ ବ୍ରେକେ ମାରି ଅଟକୁଛ । ଏହା ସୁନ୍ଦର ଓ ସୁରକ୍ଷିତ!

- Step Decay (ତୁଳନା ପାଇଁ): ଏହା ଯପେରି ହଠାତ ବ୍ରେକେ ମାରିବା । ଝଟକା ଲାଗେ!

ବାସ୍ତବ ଉଦାହରଣ: ଏରୋପ୍ଲେନ ଅବତରଣ (landing) ସମୟରେ ଧୀରେ ଧୀରେ ନିଚକୁ ଆସେ, ହଠାତ ନିଚକୁ ପଡ଼େ ନାହିଁ! ସେଟା cosine decay ପରି!

ଦୁଇ config ରେ cosine decay ବ୍ୟବହାର ହେଉଛି - ଏହା ସବୁଠାରୁ ଲୋକପ୍ରିୟ schedule!

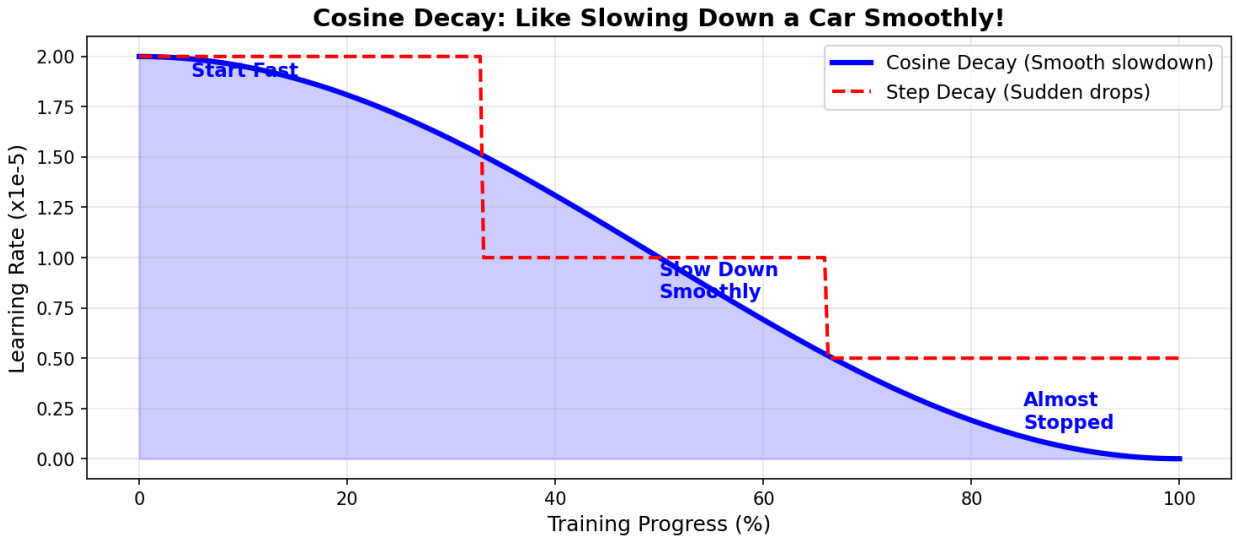

ସାରାଂଶ (Summary)

ଏହି ଅଧ୍ୟୟନରୁ ଆମେ ଶିଖିଲୁ ଯେ Fine-Tuning ରେ ସବୁଠାରୁ ଗୁରୁତ୍ୱପୂର୍ଣ୍ଣ ହେଉଛି ସଠିକ balance ବା ସନ୍ତୁଳନ । ବହୁତ ଅଧିକ ବା ବହୁତ କମ - ଦୁଇଟି ଖରାପ ।

ମୁଖ୍ୟ ଶିକ୍ଷା (Key Lessons):

1. Learning Rate ଛୋଟ ରଖ - ଧୀରେ ଚାଲ, ସଠିକ ରାସ୍ତା ପାଇବ

2. LR Scaling ଦରକାର ନାହିଁ ସବୁ ସମୟରେ - ସାମାନ୍ୟ ବଗେ ଭଲ

3. Backbone କୁ gentle ଭାବେ update କର - ଅଭିଜ୍ଞ ଲୋକଙ୍କୁ ସମ୍ମାନ ଦିଅ

4. Head Multiplier ମଧ୍ୟମ ରଖ - Volume ଠିକ ରଖ

5. Class Weights balanced ରଖ - ସମସ୍ତଙ୍କୁ ସମାନ ଧ୍ୟାନ ଦିଅ

6. Label Smoothing ବ୍ୟବହାର କର - ବିନମ୍ର ରୁହ, 100% ନିଶ୍ଚିତ ହୁଅ ନାହିଁ

7. ଛୋଟ Batch Size = ଅଧିକ ସୂକ୍ଷ୍ମ ଶିକ୍ଷା

8. Freeze-Unfreeze-Warmup ଚକ୍ର ଅନୁସରଣ କର

9. Cosine Decay ସହ ସ୍ମୁଦ ଭାବେ ଧୀରେ ହୁଅ

10. FP16 ସର୍ବଦା ବ୍ୟବହାର କର - Memory ବଞ୍ଚାଅ!

ଧନ୍ୟବାଦ! ସବୁ ଉଦାହରଣ 10 ବର୍ଷ ପିଲାଙ୍କ ପାଇଁ ସରଳ ଭାଷାରେ ଲେଖାଯାଇଛି ।